Intro to R - Volume 2.2

Edisi Revisi

ikanx101.github.io

Agustus 6, 2020

Contents

Bayangkan Anda berada di restoran *all you can eat* dimana semua makanan yang Anda mau ada semua di sana... Ikang

---

Untuk apa saya belajar R?

Di era digitalisasi ini, disadari atau tidak data tersebar di mana-mana. Data juga dihasilkan dengan *volume* yang besar dalam waktu singkat.

> *Analoginya seperti ada sungai yang memiliki arus yang deras dan kencang.* Seperti itulah kondisi saat ini.

Tools analisa data klasik seperti **Ms. Excel** dan **SPSS** sudah tidak mampu lagi melakukan analisa *big data* yang seringkali berbentuk *unstructured data*.

R tidak sendirian, ada juga *software* lain bernama **Python**. Keduanya digunakan untuk membuat algoritma *artificial intelligence* (bahasa keren dari *machine learning*. Bahasa kerennya dari *computational science*).

---

1 Pendahuluan

R merupakan salah satu bahasa pemrograman yang biasa digunakan untuk menyelesaikan permasalahan terkait dengan data. Kita bisa membuat model prediksi (*machine learning*, *artificial intelligence*, dan *deep learning*) sampai membuat algoritma automasi menggunakan **R**.

> Apa perbedaan R dan Python? Salah satu kelebihan **R** adalah:
>
> R is made by statistician for statistician. Setiap *package* atau *library* yang di-*launching* di **R** biasanya disertakan dengan jurnal ilmiah sehingga kita bisa dengan yakin memakainya.

R tersedia secara *open source* sehingga *software* ini gratis dan dikembangkan secara massal oleh komunitas-komunitas di seluruh dunia. Sehingga *package* atau *library* yang disediakan untuk analisis statistika dan analisa numerik juga sangat lengkap dan terus bertambah setiap saat.

Bagaimana dengan **Python**?

> Sejatinya Python digunakan untuk membangun aplikasi. Namun, belakangan ini ternyata Python disadari bisa untuk melakukan pengolahan data. Berbeda dengan **R** yang memang dibangun untuk kebutuhan *data science*, **Python** membutuhkan *libraries* setiap kali melakukan pengolahan data.

Materi *training* ini saya kumpulkan dari berbagai sumber dan saya *customize* sesuai dengan kebutuhan **Nutrifood** berdasarkan pengalaman selama ini berkutat dengan data yang ada (dari mulai data pabrik hingga *finance*). Semoga menjadi manfaat bagi *Nutrifooders* semua.

1.1 Sejarah

R Merupakan bahasa yang digunakan dalam komputasi statistik yang pertama kali dikembangkan oleh *Ross Ihaka* dan *Robert Gentlement* di *University of Auckland New Zealand* yang merupakan akronim dari nama depan kedua pembuatnya. Sebelum **R** dikenal ada **S** yang dikembangkan oleh *John Chambers* dan rekan-rekan dari *Bell Laboratories* yang memiliki fungsi yang sama untuk komputasi statistik. Hal yang membedakan antara keduanya adalah **R** merupakan sistem komputasi yang bersifat gratis.

1.2 Fitur dan Karakteristik

Sama halnya dengan bahasa pemograman lainnya. Berbeda bahasa berarti berbeda peraturan / cara menulis *code* (algoritma). Tapi jangan khawatir, dengan memanfaatkan *tidy principle* di **R**, kita bisa menulis algoritma dengan mudah (bagi kita dan pembaca algoritmanya).

> Oleh karena itu, menurut saya **R** menawarkan *learning curve* yang jauh lebih baik dibandingkan *Python*. Beberapa karakter dari **R** adalah sebagai berikut:

1. Bahasa **R** bersifat *case sensitive*. Setiap perbedaan cara penulisan (kapital vs non kapital) akan membedakan suatu objek. Contoh:

```
x = 'Nutrifood'
y = 'nutrifood'
x == y
```

```
## [1] FALSE
```

2. Segala sesuatu yang ada pada program **R** akan diangap sebagai objek. konsep objek ini sama dengan bahasa pemrograman berbasis objek yang lain seperti *Java*, *C++*, *Python*, dll. Perbedaannya adalah bahasa **R** relatif lebih sederhana dibandingkan bahasa pemrograman berbasis objek yang lain.
3. *Interpreted language* atau *script*. Bahasa **R** memungkinkan pengguna untuk melakukan kerja pada **R** tanpa perlu melakukan *compile* menjadi *executionable* file (.exe).
4. Mendukung proses *loop*, *decision making*, dan menyediakan berbagai jenis operator (aritmatika, logika, dll).
5. Mendukung *export* dan *import* berbagai *format file*, seperti: `.txt`, `.xlsx`, `.csv`, `.json`, `sql`, dll.
6. Mudah ditingkatkan melalui penambahan fungsi atau *library*. Penambahan ini dapat dilakukan secara *online* melalui **CRAN** atau melalui sumber seperti **github**.
7. Menyedikan berbagai fungsi untuk keperluan visualisasi data. Visualisasi data pada **R** dapat menggunakan *library* bawaan atau lainnya seperti `ggplot2`, `ggvis`, `plotly`, dll.

1.3 Kelebihan dan Kekurangan R

Selain karena **R** dapat digunakan secara gratis terdapat kelebihan lain yang ditawarkan, antara lain:

1. *Protability*, penggunaan *software* dapat digunakan kapanpun tanpa terikat oleh masa berakhirnya lisensi.
2. *Multiplatform*, **R** bersifat *Multiplatform Operating Systems*, dimana **R** bisa dijalankan di OS manapun. Baik Windows, iOS, Linux, Raspbian, bahkan Android! Dengan fitur yang sama (tidak ada perbedaan fitur di semua OS).
3. *Programable*, pengguna dapat membuat fungsi dan metode baru atau mengembangkan modifikasi dari analisis statistika yang telah ada pada sistem **R**.
4. Fasiltas grafik yang lengkap.

Adapun kekurangan dari R antara lain:

- *Point and Click GUI*, interaksi utama dengan **R** bersifat **CLI** (*Command Line Interface*), walaupun saat ini telah dikembangkan *library* yang memungkinkan kita berinteraksi dengan **R** menggunakan **GUI** (*Graphical User Interface*) sederhana menggunakan `library(R-Commander)` yang memiliki fungsi yang terbatas.

1.4 R vs R Studio

Pada dasarnya, *software* **R** bisa di-*download* dan di-*install* langsung dari situs CRAN. *Software* **R** ini bersifat **CLI**.

> Bayangkan Anda membuka aplikasi **notepad**. Putih dan bersih kan? Seperti itulah *software* **R**.

Bagi Kamu yang kaget dan tidak terbiasa melihat tampilan yang *intimidating* seperti itu, Kamu bisa meng-*install software* **R Studio**. Sebuah *software* GUI yang bisa membuat **R** terlihat lebih *user friendly*. **R Studio** bisa di-*download* di sini.

> Tapi tolong diperhatikan bahwa **R Studio** hanya tambahan tampilan dari **R** standar. Jadi Kamu tetap harus meng- *install* **R** yah!

Kelebihan R Studio antara lain:

1. *Free*, kita bisa memilih versi gratis dari **R Studio** tanpa ada pengurangan fitur dasar dari **R**.
2. *R Studio Cloud*, tersedia layanan *cloud* sehingga bisa diakses dan digunakan menggunakan *browser* di *gadget* manapun. Layanan *cloud* ini bisa diakses di sini dan dikoneksikan ke akun **github** Kamu. Kira-kira seperti ini tampilannya jika dibuka di *Chrome for Android*:

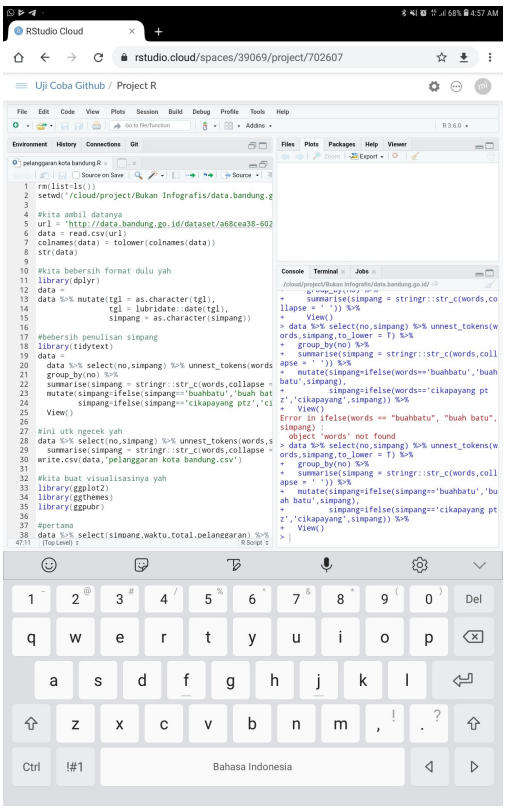

3. *Shiny Apps*, kita bisa membuat *apps* berbasis *web* dari **R**. *Apps* ini bisa dijadikan *dashboard* atau mesin kalkulasi otomatis. Tergantung seberapa jauh Kamu membuat *coding* algoritmanya.
4. *R Markdown*, ini fitur yang paling saya sukai. Bahkan untuk menulis *web* ini, saya menggunakan *R Markdown*. Output files -nya beragam, mulai dari `docx`, `pptx`, `pdf`, `html`, `md`, dll. Bahkan kita bisa membuat *e-book* dengan memanfaatkan `library(bookdown)`.

Jadi, setelah membaca bagian ini pastikan Kamu sudah meng- *install* **R** dan **R Studio** yah.

> Jangan sampai terbalik urutan instalasinya!

1.5 Mengenal operator dasar

Beberapa operator dasar di **R** antara lain:

1. `=` atau `<-`, digunakan untuk melakukan pendefinisian suatu objek. Contoh:

```
a = 10
b <- 3
a + b
```

```
## [1] 13
```

2. `' '` atau `" "`, digunakan untuk menandai tipe variabel berupa `character`. Lalu apa beda penggunaan `' '` dengan `" "`? `" "` digunakan saat `'` dibutuhkan dalam suatu `character`. Contoh:

```
a = 'saya hendak pergi ke pasar'
b = "i don't want to buy it"
a
```

```
## [1] "saya hendak pergi ke pasar"
```

```
b
```

```
## [1] "i don't want to buy it"
```

3. `==`, `<`, `>`, `<=`, atau `>=`, digunakan untuk mengecek apakah dua variabel itu memiliki kesamaan atau tidak. *Output* dari operator ini adalah `logic` (*TRUE or FALSE*). Contoh:

```
a = 5
b = 3
a == b
```

```
## [1] FALSE
```

```
a > b
```

```
## [1] TRUE
```

4. `;` atau , digunakan untuk memisahkan baris kode pada skrip algoritma. Contoh:

```
a = 5;b = 3;a*b
```

```
## [1] 15
```

1.6 Working Directory

Apa itu *working directory*?

> *Working directory* adalah *folder path default* untuk **R** melakukan *import* dan *export* data. Untuk mengetahui di mana *working directory* kita, bisa digunakan perintah:

```
getwd()
```

```
## [1] "/home/ikanx101githubio/Documents/belajaR/Materi Training/Day 1 - R Series"
```

Secara *default*, **R** menggunakan `C:\\My Documents` sebagai *working directory*.

1.6.1 Bagaimana mengubah *working directory*?

Working directory bisa diubah sesuai kemauan kita memanfaatkan perintah `setwd()`, tanda dalam kurung diisi dengan *folder path* yang diinginkan.

```
setwd("~/Documents/belajaR/Materi Training/Day 1 - R Series")
```

1.6.2 Apa keuntungan mengubah-ubah *working directory*?

Perubahan *working directory* akan sangat berguna saat kita ingin memgambil data dari *folder path* tertentu dan menyimpan hasil analisa kita ke *folder path* yang berbeda.

1.7 Mengenal *packages* atau *library*

`packages` atau `library` adalah sekumpulan fungsi yang telah dibuat dan dibakukan untuk kemudian disertakan di halaman *web* CRAN atau github. `library` bisa kita *install* dan gunakan dengan mudah.

Seperti yang sudah saya infokan di bagian pendahuluan. Banyak orang atau komunitas yang mengembangkan berbagai macam `library` sehingga memudahkan kita untuk menyelesaikan masalah di data kita. Kita tidak perlu lagi membuat algoritma dari nol. Cukup memanfaatkan `library` yang tepat saja.

Beberapa contoh `library` yang sering saya gunakan:

1. `dplyr`: *data carpentry* menggunakan *tidy principle*.
2. `ggplot2`: *data visualization*.
3. `rvest`: *web scraping*.
4. `tidytext`: *text analysis*.
5. `reshape2`: *data manipulation*.
6. `readxl` atau `openxlsx`: *export* dan *import excel files*.
7. `officer`: membuat *Ms. Office files* seperti *excel*, *docx*, dan *powerpoint*.
8. `expss`: **SPSS** di **R**.
9. `xaringan`: membuat *file* presentasi berformat `html`.

1.7.1 Instalasi *Packages*

`library` di **R** bisa di-*install* dengan mudah dengan menggunakan perintah `install.packages('nama packages')`. Tanda dalam kurung diisi `character` nama `library`. Bisa menggunakan `" "` atau `' '`.

Proses instalasi `library` ini membutuhkan koneksi internet karena **R** akan otomatis terhubung ke dalam situs *web* **CRAN**. Setelah proses instalasi selesai, maka koneksi internet tidak diperlukan lagi (kecuali untuk melakukan *web scraping*).

Contoh:

```
install.packages('readxl')
```

```
install.packages("rvest")
```

1.7.2 Mengaktifkan *Packages*

`library` yang sudah di-*install* bisa diaktifkan dengan menggunakan perintah `library(nama packages)` tanpa menggunakan tanda `" "` atau `' '`.

Pengaktifan `library` cukup dilakukan sekali saja di awal pengerjaan *project* (tidak perlu dilakukan berulang kali). Contoh:

```
library(dplyr)
```

Beberapa `library` saat diaktifkan akan menghasilkan pesan tertentu seperti di atas ini. Hal ini merupakan sesuatu yang **normal** terjadi.

1.7.3 Serba-Serbi Tentang *Packages*

Untuk beberapa `library` ada kemungkinan (kecil) ditemukan kasus saat mereka tidak kompatibel. Akibatnya beberapa fungsi perintah di `library` tersebut akan menjadi kacau.

Misalnya pada saat kita memanggil `library(tidyverse)` dan `library(plyr)`, maka perintah `filter()` yang dimiliki `tidyverse` akan tidak berjalan dengan baik.

Ada beberapa solusi yang bisa kita lakukan:

1. Selalu mengaktifkan `library` sesuai dengan urutannya. Biasanya setiap kali kita mengaktifkan `library` akan muncul *warnings* mengenai kompatibilitas `library` tersebut dengan `library` lain.
2. Menonaktikan `library` yang sudah tidak perlu digunakan dengan perintah:

```
detach("package:tidytext", unload = TRUE)
```

3. Memanggil `library` tanpa harus mengaktifkannya. Kita bisa melakukannya dengan menggunakan tanda `nama packages::`. Contoh:

```
reshape2::melt(data)
```

1.7.4 *Help*

Setiap `library` yang telah di-*install* dan aktif disertai dengan fitur *help* yang berfungsi sebagai informasi kepada *user*. Jika kita ingin mengetahui bagaimana isi dari perintah suatu fungsi, kita bisa gunakan perintah `help(nama fungsi)` atau `?nama fungsi`. *Help* akan muncul pada tab *help* di **R Studio**. Contoh:

```
help(sum)
```

atau

```
?sum
```

1.7.5 *Example*

Selain *help*, kita bisa melihat contoh pemakaian dari suatu fungsi di **R** dengan menggunakan perintah `example()`. Contoh:

```
example(sum)
```

```
##
## sum> ## Pass a vector to sum, and it will add the elements together.
## sum> sum(1:5)
## [1] 15
##
## sum> ## Pass several numbers to sum, and it also adds the elements.
## sum> sum(1, 2, 3, 4, 5)
## [1] 15
##
## sum> ## In fact, you can pass vectors into several arguments, and everything gets added.
## sum> sum(1:2, 3:5)
## [1] 15
##
## sum> ## If there are missing values, the sum is unknown, i.e., also missing, ....
## sum> sum(1:5, NA)
## [1] NA
##
## sum> ## ... unless  we exclude missing values explicitly:
## sum> sum(1:5, NA, na.rm = TRUE)
## [1] 15
```

2 Mulai Bekerja dengan R

2.1 Mengenal Data

Sebelum memulai bekerja dengan **R**, ada baiknya saya jelaskan dan ingatkan kembali beberapa hal penting terkait data. Dengan demikian, kita bisa memilih jenis analisa statistika apa yang tepat untuk tipe-tipe data yang berbeda.

2.1.1 Tipe Data (statistika)

Secara statistika, berikut adalah pembagian data berdasarkan tipenya:

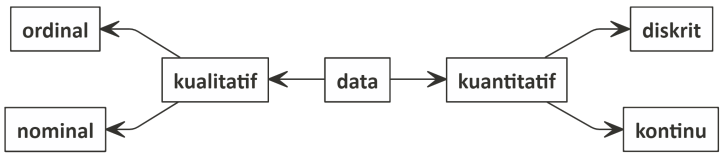

1. Data kualitatif: adalah data yang tidak bisa dilakukan operasi aritmatika (penjumlahan, pengurangan, pembagian, dan perkalian). Data seperti ini, kita akan sebut sebagai **data kategorik**.

- **Nominal**; Representasi dari sesuatu. Contoh: `gender`, `1` saya tulis sebagai `pria` dan `2` saya tulis sebagai `wanita`.
- **Ordinal**; Urutan dari data menjadi penting. Contoh: skala *likert* 1 - 6.

2. Data kuantitatif: adalah data yang bisa dilakukan operasi aritmatika (penjumlahan, pengurangan, pembagian, dan perkalian). Data seperti ini, kita akan sebut sebagai **data numerik**.

- **Diskrit**; bilangan bulat (*integer*).
- **Kontinu**; bilangan *real* (mengandung koma).

2.1.2 Tipe Data di R

Di **R** ada beberapa tipe data yang sering digunakan. Secara hierarki, bisa diurutkan sebagai berikut:

`character > numeric > integer > logical`

Oke, saya coba jelaskan satu persatu yah:

1. `character`: merupakan tipe data berupa karakter atau `string`. Semua data bisa dilihat sebagai `character`. Oleh karena itu, secara hierarki tipe data ini ditempatkan di urutan paling atas. Namun, data tipe ini tidak bisa dilakukan operasi aritmatika *yah*.
2. `numeric`: merupakan tipe data angka berupa bilangan *real*. Kalau saya boleh bilang, tipe data ini mirip dengan data numerik di poin **2.1.1**.
3. `integer`: merupakan tipe data angka berupa bilangan bulat. Sekilas mirip dengan tipe data diskrit di poin **2.1.1**. Namun di beberapa kondisi, tipe data ini bisa dijadikan data **kategorik** sehingga kita bisa sebut tipenya menjadi `factor`.
4. `logical`: merupakan tipe data *boolean*. Hanya berisi `TRUE` atau `FALSE`. Tipe data ini sangat berguna saat kita melakukan *if conditional*, *looping*, atau membuat *regex* (*reguler expression*).

2.1.3 Struktur Data di R

Ada beberapa bentuk struktur data di **R**, yakni:

1. *Single value*; satu objek yang berisi satu *value* saja.
2. *Vector*; kumpulan dari beberapa *single value(s)* yang menjadi satu objek. Bayangkan sebagai satu buah kolom di *file Ms. Excel*.
3. *Data frame* atau *tibble*; merupakan kumpulan dari beberapa *vectors* yang memiliki ukuran sama. Bayangkan sebagai satu tabel di *Ms. Excel* yang banyaknya baris di setiap kolom sama.
4. *List*; merupakan bentuk struktur data yang sangat kompleks. Berisi *multiple data* dengan struktur bermacam-macam.

2.1.4 Apa gunanya kita mengetahui jenis dan struktur data di R?

Beberapa algoritma yang tersedia di *library* mengharuskan kita memiliki *input* yang ter-standar, baik dari segi jenis dan strukturnya.

Dengan mengetahui jenis dan struktur data, kita bisa lebih mudah bekerja dengan algoritma yang ada di *library*.

Contoh:

> Algoritma analisa *simple linear regression* (`lm()`) memerlukan input berupa `data.frame()` dengan masing-masing *variables* yang ada di dalamnya berjenis *numeric*.

2.2 Tata Cara Memberikan Nama *Object* atau Variabel

Setiap *object* atau variabel di **R** bisa diberikan nama sesuai dengan keinginan kita. Tidak ada aturan baku dalam memberikan nama.

> Tapi, dengan memberikan nama yang **tepat** kita bisa bekerja dengan ebih cepat dan efisien. Berikut adalah tata cara pemberian nama yang akan membuat pekerjaan kita lebih efisien:

1. Seragamkan kapital atau non kapital dari nama variabel kita. Jika menggunakan *lowercase*, maka harus konsisten di setiap data yang ada di *environment* **R**.
2. Hindari penggunaan spasi " “. Jika memang tidak bisa dihindari, gunakan tanda”." atau "_".

- Contoh: variabel `tinggi badan` akan lebih baik ditulis dalam bentuk `tinggi.badan` atau `tinggi_badan`. Jika sudah terlanjur memiliki nama variabel yang tidak seragam atau mengandung spasi (biasanya terjadi saat kita meng- *import* data dari sumber lain seperti: *excel*), kita bisa merapikannya dengan otomatis dengan memanfaatkan `library(janitor)` fungsi `make_clean_names()` atau `clean_names()`.

---

3 Memulai dengan R

Oke, kita akan memulai bekerja dengan **R**, dimulai dari fungsi-fungsi awal sebagai berikut:

3.1 Fungsi Awal

3.1.1 Pendefinisian *object*

Setiap data yang akan kita masukkan ke dalam memori **R**, akan saya sebut sebagai *object*. Setiap *object* yang ingin dimasukkan ke dalam memori perlu didefinisikan terlebih dahulu menggunakan perintah `=` atau `<-`.

Contoh:

Jika saya ingin mendefinisikan dua buah *objects*, yakni `a` dan `b` sebagai berikut:

```
a = 6
b <- 8
```

Maka:

```
a
```

```
## [1] 6
```

```
b
```

```
## [1] 8
```

3.1.2 Operasi Aritmatika dan Matematika

Setiap *object* yang sudah masuk ke dalam memori **R** sudah bisa dilakukan analisa atau dilakukan operasi aritmatika: `+`, `-`, `/`, dan `*` ATAU diberikan fungsi matematika seperti **trigonometri**, **logaritmik**, dan lain-lain.

Pada *section* `3.1.1` kita telah mendefinisikan *objects* `a` dan `b`, maka kita bisa lakukan perintah sebagai berikut:

```
a + b
```

```
## [1] 14
```

```
a / b
```

```
## [1] 0.75
```

```
c = a * b
c
```

```
## [1] 48
```

```
sin(c)
```

```
## [1] -0.7682547
```

```
log(a+b/c)
```

```
## [1] 1.819158
```

3.1.3 Operasi Relasi dan *Logical* (*Boolean*)

Pada *section* `1.5` poin 3, kita telah mengetahui operator relasi seperti `==`, `>`, `<`, `<=`, `>=`, dan `!=`. Hasil dari operator relasi ini adalah *logical value* (**TRUE** atau **FALSE**).

Logical value yang dihasilkan memiliki sifat sebagai berikut:

1. `TRUE`, berarti **benar**. Bisa disingkat menjadi `T`. Tidak bisa ditulis dalam huruf kecil (harus kapital).
2. `FALSE`, berarti **salah**. Bisa disingkat menjadi `F`. Tidak bisa ditulis dalam huruf kecil (harus kapital).

Operator logical yang biasa digunakan di **R** antara lain:

1. `&` menandakan **AND**
2. `|` menandakan **OR**
3. `!` menandakan **NOT**

Contoh:

Misalkan saya memiliki dua pernyataan sebagai berikut:

```
pernyataan_1 = T
pernyataan_2 = F
```

Maka:

```
!pernyataan_1
```

```
## [1] FALSE
```

```
pernyataan_1 & pernyataan_2
```

```
## [1] FALSE
```

```
pernyataan_1 | pernyataan_2
```

```
## [1] TRUE
```

3.1.4 *If Conditional*

Mungkin teman-teman bertanya-tanya:

> Apa sih gunanya *logical value* dan *logical operator*? *Logical value* merupakan unsur utama saat kita hendak membuat fungsi *conditional* dan *looping*. Masih ingat fungsi di **Ms. Excel** untuk membuat *conditional*? *Nah*, mirip pengerjaannya di **R**.

Setidaknya ada tiga fungsi *conditional* di **R**, yakni:

1. `ifelse()`: bawaan dari *package* `base`.
2. `if_else()`: fungsi dari *package* `dplyr` (perlu di- *install* dulu *package*-nya).
3. `case_when()`: fungsi dari *package* `dplyr` (perlu di- *install* dulu *package*-nya).

Apa perbedaan ketiganya?

`ifelse()` dengan `if_else()` berdasarkan pengalaman saya tidak ada perbedaannya. Selama ini saya cukup memilih salah satu saja.

Sedangkan `case_when()` digunakan bersamaan dengan *pipe* `%>%` pada saat *tidying data*. Berguna saat kita hendak mem- *vector*-kan *conditional*.

> Masih bingung? Saya akan bahas fungsi `ifelse()` dulu *yah*. Pembahasan mengenai `case_when()` akan saya jelaskan pada *section* khusus mengenai `tidyverse`.

Contoh paling mudah untuk *conditional* seperti ini:

Misalkan saya memiliki dua buah *objects*, yakni `a` dan `b`.

```
a = 10
b = 10 + sin(pi/3)
```

Maka:

```
ifelse(a < b, 'hari ini cerah','hari ini mendung')
```

```
## [1] "hari ini cerah"
```

```
ifelse(a == b, 'sama-sama','tidak bersama')
```

```
## [1] "tidak bersama"
```

3.2 Bekerja dengan data

Pada *section* `2.1.2` telah dijelaskan beberapa struktur data di **R**, sekarang kita akan melihat bagaimana bentuk *real*-nya di **R**.

Untuk data berbentuk `list`, akan saya jelaskan sekalian bersamaan dengan materi `tidyverse` *yah*.

3.2.1 *Single Value*

Contoh:

```
a = 100
x = 50
z = 'Indonesia'
```

3.2.2 *Vector*

Vector didefinisikan dengan menggunakan perintah `c()`; merupakan

Contoh:

```
tinggi_badan = c(164,149,180,184,153,90,139,199,186,158,197)
tinggi_badan
```

```
##  [1] 164 149 180 184 153  90 139 199 186 158 197
```

3.2.2.1 Elemen *Vector* Ada yang sadar *gak* dengan tanda `[1]` setiap kali kita *running* suatu skrip di **R**.

Apa *sih* artinya?

Itu adalah tanda posisi pertama dari *vector*. Tanda `[]` digunakan untuk memanggil isi *vector* di posisi tertentu. Istilah kerennya adalah *subset* dari suatu *vector*.

Contoh:

```
tinggi_badan[1]
```

```
## [1] 164
```

```
tinggi_badan[7]
```

```
## [1] 139
```

```
tinggi_badan[10]
```

```
## [1] 158
```

```
tinggi_badan[3:5]
```

```
## [1] 180 184 153
```

```
tinggi_badan[c(1,7,10)]
```

```
## [1] 164 139 158
```

```
tinggi_badan[-c(1,7,10)] #pengeculian
```

```
## [1] 149 180 184 153  90 199 186 197
```

3.2.2.2 Operasi Aritmatika Pada *Vector*

Vector yang berupa numerik bisa dilakukan operasi aritmatik.

Contoh:

```
status = (tinggi_badan - 100)/50
status
```

```
##  [1]  1.28  0.98  1.60  1.68  1.06 -0.20  0.78  1.98  1.72  1.16  1.94
```

3.2.2.3 Fungsi Pada *Vector*

Vector berupa numerik juga bisa dikenakan fungsi perhitungan seperti:

```
max(tinggi_badan) # memperoleh nilai maksimum x
```

```
## [1] 199
```

```
min(tinggi_badan) # memperoleh nilai minimum x
```

```
## [1] 90
```

```
range(tinggi_badan) # memperoleh range vektor x
```

```
## [1]  90 199
```

```
length(tinggi_badan) # memperoleh jumlah vektor x
```

```
## [1] 11
```

```
sum(tinggi_badan) # memperoleh total penjumlahan vektor x
```

```
## [1] 1799
```

```
mean(tinggi_badan) # memperoleh nilai mean vektor x
```

```
## [1] 163.5455
```

```
sd(tinggi_badan) # standar deviasi vektor x
```

```
## [1] 31.5194
```

```
var(tinggi_badan) # varian vektor x
```

```
## [1] 993.4727
```

```
sort(tinggi_badan) # mengurutkan elemen vektor x dari yang terbesar
```

```
##  [1]  90 139 149 153 158 164 180 184 186 197 199
```

3.2.2.4 ***Generating Sequences*** *Sequences* atau deret bisa kita bangun menggunakan **R** dengan dua cara:

1. Menggunakan `:`.
2. Menggunakan fungsi `seq()`.

Contoh:

```
nomor_1 = c(1:10)
nomor_1
```

```
##  [1]  1  2  3  4  5  6  7  8  9 10
```

```
# perintah untuk menghitun gcumulative sum
cumsum(nomor_1)
```

```
##  [1]  1  3  6 10 15 21 28 36 45 55
```

```
nomor_2 = seq(1,10,0.4) # generating sequence dari 1 hingga 10 dengan jeda 0.4
nomor_2
```

```
##  [1] 1.0 1.4 1.8 2.2 2.6 3.0 3.4 3.8 4.2 4.6 5.0 5.4 5.8 6.2 6.6 7.0 7.4 7.8 8.2
## [20] 8.6 9.0 9.4 9.8
```

> Apa sih gunanya deret? Percayalah, suatu saat nanti deret bisa digunakan untuk membantu perhitungan atau analisa kita. Seolah-olah berperan sebagai **katalis** pada reaksi kimia.

3.2.2.5 ***Random sampling*** **dari suatu** ***vector*** Ada suatu masa saat kita membutuhkan untuk mengambil sampel (mengambil subset) dari suatu *vector* secara acak. Kita bisa menggunakan fungsi `sample()`.

Contoh:

Kita memiliki data variabel `nama_orang` berisi 20 nama orang. Kita hanya ingin memilih 3 nama orang saja secara acak. Bagaimana caranya?

```
nama_orang = randomNames::randomNames(20)
nama_orang
```

```
##  [1] "Arnold, Kenneth"          "Barron, Trever"
##  [3] "Shoemaker, Madison"       "Mcgowan, Aric"
##  [5] "Kellison, Lanae"          "Hopkins, Jonathan"
##  [7] "Flood, Julianna"          "Foster, Mya"
##  [9] "Mendoza, Tyler-Lee"       "Ong, Cooper"
## [11] "Smith, Kristen"           "Porter, Jessica"
## [13] "Nhem, Jonathan"           "Montgomery, Melissa"
## [15] "al-Khan, Mufeeda"         "Colunga, Nicklos"
## [17] "al-Obeid, Rasheeda"       "Gonzalez-Saucedo, Robert"
## [19] "Smith II, Elizandra"      "Sterling, Frederick"
```

```
sample(nama_orang,3,replace = F)
```

```
## [1] "Nhem, Jonathan"     "Barron, Trever"     "Shoemaker, Madison"
```

`replace = F` digunakan saat kita tidak ingin ada pemilihan yang berulang. Sedangkan `replace = T` digunakan saat diperbolehkan hasil pemilihan berulang. Coba *run* sendiri *yah*.

Perintah `sample()` ini akan sangat berguna saat kita hendak menggunakan prinsip simulasi **Monte Carlo**.

3.2.2.6 ***Repeat*** Adakalanya kita hendak melakukan pengulangan yang simpel. *Instead of using looping*, kita bisa menggunakan perintah `rep()`. Misalkan:

```
rep('belajar R',3)
```

```
## [1] "belajar R" "belajar R" "belajar R"
```

```
rep(c(4:8),10)
```

```
##  [1] 4 5 6 7 8 4 5 6 7 8 4 5 6 7 8 4 5 6 7 8 4 5 6 7 8 4 5 6 7 8 4 5 6
## [39] 7 8 4 5 6 7 8 4 5 6 7 8
```

```
tinggi_badan = c(120,132,142,90)
rep(mean(tinggi_badan),4)
```

```
## [1] 121 121 121 121
```

Jadi perintah `rep()` tidak hanya bisa untuk mengulang suatu single variabel atau *vector* saja tapi bisa digunakan untuk mengulang suatu fungsi.

Apa perbedaan dengan fungsi `repeat()`? Fungsi `repeat()` biasanya digunakan dalam *looping* dan baru akan berhenti saat diberikan perintah `break`.

3.2.3 *Tibble* atau *Data Frame*

Tibble atau *data frame* adalah struktur data di **R** berupa tabel. Analogi sederhananya adalah mirip dengan tabel di **Ms. Excel** *files*.

Data frame bisa dibentuk dari beberapa *vector* yang memiliki `length()` yang sama. Contohnya berikut ini:

Kita akan membuat *data frame* dari `4` buah *vector*, yakni: `id`, `nama`, dan `tinggi_badan`.

```
id = c(1:10)
nama = randomNames::randomNames(10,gender = 0,which.names = 'first')
tinggi_badan = sample(c(150:199),10,replace = F)
absensi = data.frame(id,nama,tinggi_badan)
```

Hasilnya seperti ini:

```
absensi
```

```
##    id     nama tinggi_badan
## 1   1  Brandon          161
## 2   2     Sean          190
## 3   3 Jonathan          193
## 4   4  Tawfeeq          181
## 5   5   Talaal          191
## 6   6   Miguel          187
## 7   7   Mus'ab          152
## 8   8     Adam          173
## 9   9  Antonio          151
## 10 10  Trenten          175
```

Bentuk *data frame* kelak akan menjadi primadona dalam setiap analisa yang digunakan di **R**. Nanti saat kita belajar *data carpentry* menggunakan `tidyverse`, struktur *data frame* mudah dimanipulasi dengan *piping operator*: `%>%`.

3.2.4 *Missing values* `NA`

Missing values adalah suatu nilai yang kosong pada suatu data. Kosong berarti tidak berisi data apapun. Bedakan dengan nilai `0` yah!

> `NA` tidak akan diikutsertakan dalam perhitungan sedangkan `0` diikutsertakan. Di **R**, nilai `NA` pada data numerik akan membuat *error* setiap kali dihitung.

Contoh:

```
data_1 = c(3,5,0,6,8,3)
mean(data_1)
```

```
## [1] 4.166667
```

Berikut adalah contoh saat ada data berisi `NA`, maka data tersebut tidak akan bisa dihitung:

```
data_2 = c(3,5,NA,6,8,3)
mean(data_2)
```

```
## [1] NA
```

Bagaimana cara mengecek keberadaan `NA` di data kita?

Kita bisa menggunakan fungsi `is.na()`. *Output* dari fungsi ini adalah *boolean variable* berupa `TRUE` atau `FALSE`.

Contoh: mengecek apakah ada `NA` di `data_2`.

```
is.na(data_2)
```

```
## [1] FALSE FALSE  TRUE FALSE FALSE FALSE
```

Contoh: membuat tabulasi dari *function* `is.na()`.

```
table(is.na(data_2))
```

```
##
## FALSE  TRUE
##     5     1
```

Contoh: menghitung seberapa banyak yang `TRUE`.

```
sum(is.na(data_2))
```

```
## [1] 1
```

Contoh: mengecek apakah ada data yang **TIDAK** `NA` di `data_2`.

```
!is.na(data_2)
```

```
## [1]  TRUE  TRUE FALSE  TRUE  TRUE  TRUE
```

3.3 Beberapa Fungsi yang Berguna

3.3.1 *Paste*

> Apakah kalian mengetahui fungsi bernama **CONCATENATE** di **Ms. Excel**? Fungsi `paste()` mirip penggunaannya dengan perintah **CONCATENATE**, yakni menggabungkan beberapa data menjadi satu.

Contoh: membuat *vector* berisi `nama_toko` yang berisi urutan nama toko.

```
nama_toko = paste('toko ke',c(1:10),sep='-')
nama_toko
```

```
##  [1] "toko ke-1"  "toko ke-2"  "toko ke-3"  "toko ke-4"  "toko ke-5"
##  [6] "toko ke-6"  "toko ke-7"  "toko ke-8"  "toko ke-9"  "toko ke-10"
```

Contoh: membuat *vector* dari `nama_toko` yang sudah pernah dibuat sebelumnya dengan *rules* `5` toko pertama dari Bandung dan `5` toko selanjutnya dari Bekasi.

```
nama_toko = paste(nama_toko,rep(c('Bandung','Bekasi'),5))
nama_toko
```

```
##  [1] "toko ke-1 Bandung" "toko ke-2 Bekasi"  "toko ke-3 Bandung"
##  [4] "toko ke-4 Bekasi"  "toko ke-5 Bandung" "toko ke-6 Bekasi"
##  [7] "toko ke-7 Bandung" "toko ke-8 Bekasi"  "toko ke-9 Bandung"
## [10] "toko ke-10 Bekasi"
```

`sep =` berguna untuk mendefinisikan *separator* apa yang hendak digunakan. Secara *default*, *separator* yang digunakan adalah spasi.

Coba kalian ganti sendiri bagian *separator*-nya.

3.3.2 *Print*

Fungsi `print()` digunakan untuk menampilkan data ke layar. Biasanya digunakan pada proses *looping* agar hasil iterasi dapat tampil ke layar.

```
print(nama_toko)
```

```
##  [1] "toko ke-1 Bandung" "toko ke-2 Bekasi"  "toko ke-3 Bandung"
##  [4] "toko ke-4 Bekasi"  "toko ke-5 Bandung" "toko ke-6 Bekasi"
##  [7] "toko ke-7 Bandung" "toko ke-8 Bekasi"  "toko ke-9 Bandung"
## [10] "toko ke-10 Bekasi"
```

3.3.3 *str*

Fungsi `str()` digunakan untuk melihat tipe dan struktur *object* yang ada di **R**. Sebagai contoh, kita akan pakai data `absensi` dari *section* **3.2.3**.

```
str(absensi)
```

```
## 'data.frame':    10 obs. of  3 variables:
##  $ id          : int  1 2 3 4 5 6 7 8 9 10
##  $ nama        : chr  "Brandon" "Sean" "Jonathan" "Tawfeeq" ...
##  $ tinggi_badan: int  161 190 193 181 191 187 152 173 151 175
```

Terlihat bahwa data `absensi` memiliki struktur **data.frame** dengan ada `3` *variables* dan `10` *observations* (baris data).

3.3.4 *Summary*

Fungsi `summary()` digunakan untuk melihat statistik deskriptif dari suatu data (tergantung dari tipe datanya). Contoh:

```
summary(absensi$tinggi_badan)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   151.0   164.0   178.0   175.4   189.2   193.0
```

3.3.5 *Class*

Fungsi `class()` digunakan untuk melihat tipe atau struktur dari suatu data. Mirip dengan fungsi `str()`, tapi tidak sampai menampilkan dengan detail. Contoh:

```
class(absensi)
```

```
## [1] "data.frame"
```

```
class(absensi$tinggi_badan)
```

```
## [1] "integer"
```

3.3.6 *View*

Fungsi `View()` (dengan huruf **V** kapital) digunakan untuk menampilkan `dataset` dalam *pop-up windows*.

3.4 *Looping*

Looping berarti pengulangan namun berbeda dengan *repeat* yang pernah kita bahas sebelumnya. Ada dua fungsi *looping* yang biasa digunakan, yakni: `for()` dan `while()`. Keduanya memiliki manfaat yang berbeda.

3.4.1 *For*

Fungsi `for()` biasa dilakukan untuk melakukan *looping* dengan syarat iterasi yang didefinisikan terlebih dahulu. Jadi kita sudah mengetahui terlebih dahulu berapa kali kita akan melakukan *looping*.

Contoh:

```
for(i in 1:10){
  print(paste('pertanyaan ke',i))
}
```

```
## [1] "pertanyaan ke 1"
## [1] "pertanyaan ke 2"
## [1] "pertanyaan ke 3"
## [1] "pertanyaan ke 4"
## [1] "pertanyaan ke 5"
## [1] "pertanyaan ke 6"
## [1] "pertanyaan ke 7"
## [1] "pertanyaan ke 8"
## [1] "pertanyaan ke 9"
## [1] "pertanyaan ke 10"
```

Contoh:

```
for(i in 1:10){
  i = 1/i
  print(round(i,3))
}
```

```
## [1] 1
## [1] 0.5
## [1] 0.333
## [1] 0.25
## [1] 0.2
## [1] 0.167
## [1] 0.143
## [1] 0.125
## [1] 0.111
## [1] 0.1
```

3.4.2 *While*

Fungsi `while()` digunakan untuk melakukan *looping* dengan sampai syarat iterasi terpenuhi. Jadi kita belum mengetahui berapa kali kita akan melakukan *looping*.

Contoh: misalkan dalam satu ruangan ada `100` orang. Saya akan membagi mereka menjadi kelompok - kelompok berisi `1` sampai `5` orang. Kira - kira ada berapa banyak kelompok yang bisa saya dapatkan?

Caranya, kita set dulu kondisi awalnya.

```
orang = 100
i = 0 # berapa banyak kelompok? awalnya nol dulu
```

Lalu kita buat iterasi dengan `while()`. Yakni mengurangi secara berkala `100` orang dengan kelompok berisi `1 - 3` orang lalu menghitung ada berapa banyak iterasi yang terjadi.

```
while(orang>0){
  n = sample(c(1:5),1)
  orang = orang - n
  i = i+1
}
```

Berapa banyak iterasi (kelompok) yang mungkin muncul:

```
i
```

```
## [1] 33
```

3.5 *Regex*

Regex adalah kepanjangan dari *reguler expression*, yakni mencari *pattern* dari data berupa *string*. *Cheatsheet* untuk *regex* bisa dilihat di sini.

Selain mengandalkan **base** dari **R**, kita juga bisa menggunakan `library(stringr)`.

Setidaknya ada dua manfaat utama dari *regular expression*, yakni:

1. *Pattern Matching*; mencari kecocokan *pattern* dari suatu data bertipe `character`.
2. *Replace Pattern*; mencari kecocokan *pattern* dan mengubahnya dari suatu data bertipe `character`.

Perbedaan cara penulisan (kapital atau *lower*) bisa kita pertimbangkan untuk dijadikan syarat pencarian atau tidak, yakni dengan penambahan `ignore.case = T` atau `ignore.case = F`.

Berikut ini adalah *syntaxes* yang ada dan digunakan untuk mencari apa:

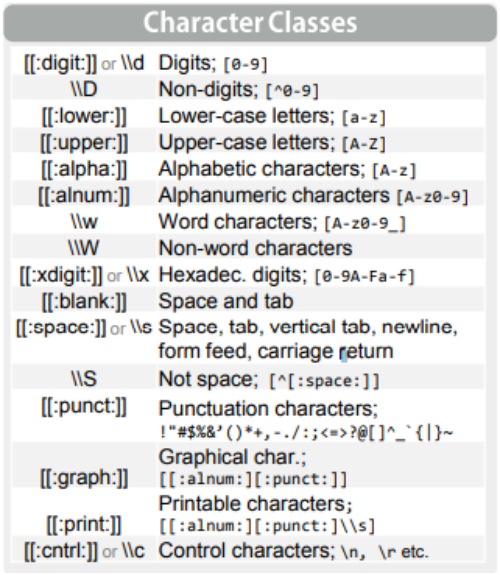

Character Classes	
[[:digit:]] or \\d	Digits; `[0-9]`
\\D	Non-digits; `[^0-9]`
[[:lower:]]	Lower-case letters; `[a-z]`
[[:upper:]]	Upper-case letters; `[A-Z]`
[[:alpha:]]	Alphabetic characters; `[A-z]`
[[:alnum:]]	Alphanumeric characters `[A-z0-9]`
\\w	Word characters; `[A-z0-9_]`
\\W	Non-word characters
[[:xdigit:]] or \\x	Hexadec. digits; `[0-9A-Fa-f]`
[[:blank:]]	Space and tab
[[:space:]] or \\s	Space, tab, vertical tab, newline, form feed, carriage return
\\S	Not space; `[^[:space:]]`
[[:punct:]]	Punctuation characters; `!"#$%&'()*+,-./:;<=>?@[]^_`{|}~`
[[:graph:]]	Graphical char.; `[[:alnum:][:punct:]]`
[[:print:]]	Printable characters; `[[:alnum:][:punct:]\\s]`
[[:cntrl:]] or \\c	Control characters; `\n`, `\r` etc.

Character Classes and Groups	
.	Any character except \n
|	Or, e.g. (a|b)
[...]	List permitted characters, e.g. [abc]
[a-z]	Specify character ranges
[^...]	List excluded characters
(...)	Grouping, enables back referencing using \\N where N is an integer

Anchors	
^	Start of the string
$	End of the string
\\b	Empty string at either edge of a word
\\B	NOT the edge of a word
\\<	Beginning of a word
\\>	End of a word

Quantifiers	
*	Matches at least 0 times
+	Matches at least 1 time
?	Matches at most 1 time; optional string
{n}	Matches exactly n times
{n,}	Matches at least n times
{,n}	Matches at most n times
{n,m}	Matches between n and m times

3.5.1 *Pattern Matching*

Sebagai contoh, saya akan gunakan data berikut ini:

Variabel *string* yang diketahui:

```
string = c('Market Research','market riset','survey','responden','mickey mouse')
```

Berikut *pattern* yang diinginkan:

```
pattern = 'm..ke'
```

Berikut adalah beberapa fungsi yang sering digunakan.

- *Function* `grep()`

Perhatikan *output* dari masing-masing perintah sebagai berikut:

```
grep(pattern,string)
```

```
## [1] 2 5
```

Output `function` ini adalah nomor urut / elemen dari *vector* yang sesuai dengan *pattern* yang diinginkan.

```
grep(pattern,string,value = T)
```

```
## [1] "market riset" "mickey mouse"
```

Output `function` ini adalah isi elemen dari *vector* yang sesuai dengan *pattern* yang diinginkan.

```
grep(pattern,string,ignore.case = T)
```

```
## [1] 1 2 5
```

Output `function` ini adalah isi elemen dari *vector* yang sesuai dengan *pattern* yang diinginkan dengan menghiraukan *uppercase* atau *lowercase*.

- *Function* `grepl()`

Output dari fungsi ini berupa *logic* (*boolean*):

```
grepl(pattern,string,ignore.case = T)
```

```
## [1]  TRUE  TRUE FALSE FALSE  TRUE
```

- *Function* menggunakan `stringr::` dan fungsi `str_detect()`

Output dari fungsi ini berupa *logic* (*boolean*):

```
stringr::str_detect(string,pattern)
```

```
## [1] FALSE  TRUE FALSE FALSE  TRUE
```

- *Function* menggunakan `stringr::` dan fungsi `str_locate()`

Find starting and end position of all matches.

```
stringr::str_locate(string, pattern)
```

```
##      start end
## [1,]    NA  NA
## [2,]     1   5
## [3,]    NA  NA
## [4,]    NA  NA
## [5,]     1   5
```

- *Function* menggunakan `stringr::` dan fungsi `str_extract()`

Extract first match.

```
stringr::str_extract(string, pattern)
```

```
## [1] NA      "marke" NA      NA      "micke"
```

3.5.2 *Replace Pattern*

Kita akan gunakan contoh data berikut ini:

Ini adalah `string` yang digunakan:

```
string = c("This is a sentence about axis",
           "A second pattern is also listed here")
```

Berikut adalah `pattern` dan `replacement` yang hendak dilakukan:

```
pattern = 'is'
replace = 'XY'
```

Berikut adalah beberapa fungsi yang sering digunakan:

`function sub()`

```
sub(pattern, replace, string)
```

```
## [1] "ThXY is a sentence about axis"
## [2] "A second pattern XY also listed here"
```

```
sub(pattern, replace, string, ignore.case = T)
```

```
## [1] "ThXY is a sentence about axis"
## [2] "A second pattern XY also listed here"
```

`function gsub()`

```
gsub(pattern, replace, string)
```

```
## [1] "ThXY XY a sentence about axXY"
## [2] "A second pattern XY also lXYted here"
```

```
gsub(pattern, replace, string, ignore.case = T)
```

```
## [1] "ThXY XY a sentence about axXY"
## [2] "A second pattern XY also lXYted here"
```

4 Membuat *function* di R.

R memungkinkan kita untuk membuat fungsi yang *custom* secara mandiri. Jika kita sering menggunakan perintah-perintah tertentu dan ingin menghemat penulisan algoritma, kita bisa membuat *custom* `function()` sendiri.

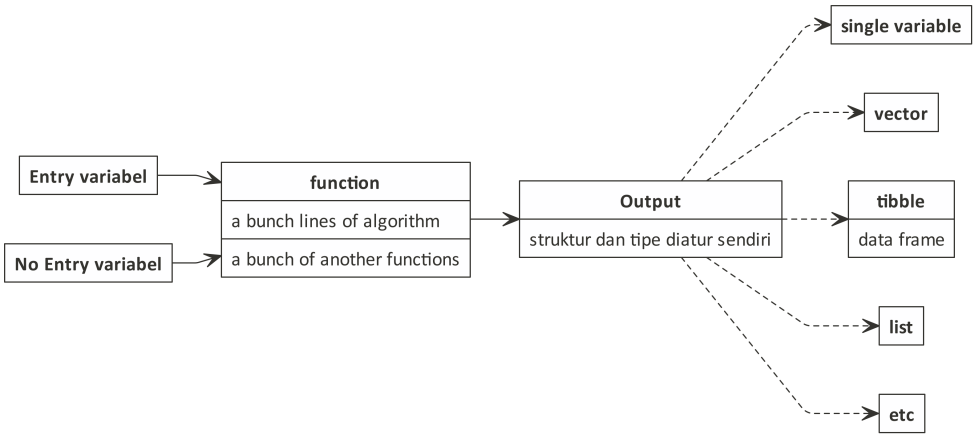

`function()` bisa memerlukan *entry variable* atau tidak memerlukan *entry variable* sama sekali.

4.1 `function()` tanpa *entry variable*

Ada kalanya kita membuat `function()` tanpa ada *entry variable*. *Lho kok gitu?*

> Tergantung dari kebutuhan kita *yah*.

Sebagai contoh, kita akan membuat `function()` yang akan men- *generate* nama orang, umur, tinggi, dan berat badan:

```
demografi = function(){
  nama = randomNames::randomNames(1)
  umur = sample(c(20:60),1)
  tinggi = rnorm(1,mean = 150, sd = 20)
  tinggi = round(tinggi,1)
  berat = rnorm(1,mean = 40, sd = 5)
  berat = round(berat,1)
  data = c(nama,umur,tinggi,berat)
  return(data)
}
demografi()
```

```
## [1] "Schulz, Emma" "24"          "155.3"       "42.2"
```

4.2 `function()` dengan *entry variable*

Entry variable yang digunakan bisa berbentuk macam-macam dan bisa lebih dari satu.

Contoh, kita akan membuat `function()` untuk mencari modus dari sebuah *vector*:

```
modus = function(x) {
  ux = unique(x)
  tab = tabulate(match(x, ux))
  ux[tab == max(tab)]
}
```

Mari kita cek apakah `function`-nya berhasil atau tidak:

```
nama = c('a','b','a','c','d')
modus(nama)
```

```
## [1] "a"
```

Contoh berikutnya kita akan buat `function()` untuk menghitung rumus pitagoras dengan dua *entry variables*, yakni `a` dan `b` sebagai berikut:

Ini adalah rumusnya:

```
pytagoras = function(a,b){
  sqrt((a^2) + (b^2))
}
```

Mari kita hitung pitagoras dengan `a = 3` dan `b = 4`, yakni:

```
pytagoras(3,4)
```

```
## [1] 5
```

5 Membaca Data dari Excel

Data yang kita temui sehari-hari biasanya memiliki format `.xlsx` atau `.xls`. Sekarang kita akan *import* data dari **Excel** untuk masuk ke dalam **R**.

Library yang digunakan adalah `library(readxl)`

Contoh data yang digunakan:

```
library(readxl)
data = read_excel('Contoh_Data.xlsx')
head(data)
```

```
## # A tibble: 6 x 8
##   dept  nama.karyawan status bulan tardines.freque~ permit.frequency
##   <chr> <chr>         <chr>  <chr>            <dbl>             <dbl>
## 1 JES   Jimenez       Tetap  Jan                  2                 2
## 2 JES   Mccarthy      Tetap  Mar                  0                 0
## 3 JES   Topaha        Tetap  Jan                  0                 1
## 4 JES   el-Ghanem     Tetap  Mar                  3                 1
## 5 JES   Topaha        Tetap  Mei                  0                 1
## 6 JES   Lofton        Tetap  Mei                  0                 2
## # ... with 2 more variables: sick.frequency <dbl>, leave.frequency <dbl>
```

5.1 Membaca Data dari Format File Lain

R memiliki kemampuan untuk membaca data dalam format lain seperti `csv`, `sav` (SPSS), `txt`, dan lainnya. Secara *default*, **R** bisa membaca file dalam bentuk `csv` dan `txt` tanpa menggunakan `library()` lainnya.

Gunakan fungsi `read.csv()` untuk membaca file `csv` dan `readLines()` untuk file `txt`.

6 Berkenalan dengan `Tidyverse`

Salah satu fungsi utama **R** adalah kemampuannya melakukan *data carpentry* untuk *dataset* berukuran besar dengan cepat. Salah satu `library` yang sering digunakan untuk melkukan *data carpentry* adalah `tidyverse`.

Salah satu ciri utama pada `tidyverse` adalah penggunaaan *piping*: `%>%` yang memiliki arti *then*.

Beberapa fungsi yang sering digunakan antara lain:

1. `filter()`
2. `select()`
3. `mutate()`
4. `group_by()` dan `summarise()`
5. `separate()`

6.1 `filter()`

Digunakan untuk melakukan filter pada data. Kita bisa menggunakan tanda `==`, `>`, `>=`, `<`, `<=`, atau `!=`.

Contohnya:

Kita hendak melakukan *filter* terhadap karyawan yang telat (*tardines*) lebih dari 10 kali dalam bulan Januari.

```
# melakukan filter:
# keterlambatan > 10
# bulan == Jan
data %>% filter(tardines.frequency>10, bulan == 'Jan')
```

```
## # A tibble: 6 x 8
##   dept  nama.karyawan status bulan tardines.freque~ permit.frequency
##   <chr> <chr>         <chr>  <chr>            <dbl>            <dbl>
## 1 JES   Herrera       Tetap  Jan                 14                1
## 2 JES   Garcia        Tetap  Jan                 19                3
## 3 ABD   Gomez         Tetap  Jan                 14                2
## 4 ABD   Sanchez       Tetap  Jan                 11                0
## 5 ABD   Archibeque    Tetap  Jan                 12                3
## 6 VIK   Sweetwater    Tetap  Jan                 14                1
## # ... with 2 more variables: sick.frequency <dbl>, leave.frequency <dbl>
```

Misalkan kita hendak melakukan *filter* untuk beberapa `dept` tertentu, kita bisa melakukan cara berikut:

```
dept_filter = c('JES','ELL','OSH')
```

Melakukan *filter* untuk `dept` tersebut:

```
data %>% filter(dept %in% dept_filter)
```

```
## # A tibble: 160 x 8
##    dept  nama.karyawan status bulan tardines.freque~ permit.frequency
##    <chr> <chr>         <chr>  <chr>            <dbl>             <dbl>
##  1 JES   Jimenez       Tetap  Jan                  2                 2
##  2 JES   Mccarthy      Tetap  Mar                  0                 0
##  3 JES   Topaha        Tetap  Jan                  0                 1
##  4 JES   el-Ghanem     Tetap  Mar                  3                 1
##  5 JES   Topaha        Tetap  Mei                  0                 1
##  6 JES   Lofton        Tetap  Mei                  0                 2
##  7 JES   Porambo       Tetap  Apr                  9                 1
##  8 JES   Porambo       Tetap  Feb                  8                 2
##  9 JES   Porambo       Tetap  Mei                  3                 2
## 10 JES   Jimenez       Tetap  Mei                  0                 2
## # ... with 150 more rows, and 2 more variables: sick.frequency <dbl>,
## #   leave.frequency <dbl>
```

Melakukan *filter* untuk **BUKAN** `dept` tersebut:

```
data %>% filter(!dept %in% dept_filter)
```

```
## # A tibble: 3,729 x 8
##    dept  nama.karyawan status bulan tardines.freque~ permit.frequency
##    <chr> <chr>         <chr>  <chr>            <dbl>             <dbl>
##  1 JAA   Rayford       Tetap  Apr                  3                 1
##  2 JAA   Rayford       Tetap  Jan                  3                 1
##  3 JAA   Rayford       Tetap  Mei                  0                 2
##  4 JAA   Rayford       Tetap  Mar                  4                 0
##  5 JAA   Rayford       Tetap  Feb                  4                 3
##  6 LOR   Schwalger     Tetap  Mei                  0                 2
##  7 LOR   Xue           Tetap  Jan                  2                 0
##  8 LOR   Xue           Tetap  Apr                  0                 1
##  9 LOR   Schwalger     Tetap  Feb                  0                 2
## 10 LOR   Kwan          Tetap  Mei                  0                 2
## # ... with 3,719 more rows, and 2 more variables: sick.frequency <dbl>,
## #   leave.frequency <dbl>
```

Perhatikan penggunaan tanda seru `!` pada skrip untuk mengaktifkan **NOT** sebelum `grepl()`.

6.2 arrange()

Digunakan untuk melakukan *sort* pada data dengan menggunakan *piping*. Kita akan *sort* berdasarkan angka `tardines` tersebut.

6.2.1 *Descending*

```
data %>%
  filter(tardines.frequency>10, bulan == 'Jan') %>%
  arrange(desc(tardines.frequency))
```

```
## # A tibble: 6 x 8
##   dept  nama.karyawan status bulan tardines.freque~ permit.frequency
##   <chr> <chr>         <chr>  <chr>            <dbl>             <dbl>
## 1 JES   Garcia        Tetap  Jan                 19                 3
## 2 JES   Herrera       Tetap  Jan                 14                 1
## 3 ABD   Gomez         Tetap  Jan                 14                 2
## 4 VIK   Sweetwater    Tetap  Jan                 14                 1
## 5 ABD   Archibeque    Tetap  Jan                 12                 3
## 6 ABD   Sanchez       Tetap  Jan                 11                 0
## # ... with 2 more variables: sick.frequency <dbl>, leave.frequency <dbl>
```

6.2.2 *Ascending*

```
data %>%
  filter(tardines.frequency>10, bulan == 'Jan') %>%
  arrange(tardines.frequency)
```

```
## # A tibble: 6 x 8
##   dept  nama.karyawan status bulan tardines.freque~ permit.frequency
##   <chr> <chr>         <chr>  <chr>            <dbl>             <dbl>
## 1 ABD   Sanchez       Tetap  Jan                 11                 0
## 2 ABD   Archibeque    Tetap  Jan                 12                 3
## 3 JES   Herrera       Tetap  Jan                 14                 1
## 4 ABD   Gomez         Tetap  Jan                 14                 2
## 5 VIK   Sweetwater    Tetap  Jan                 14                 1
## 6 JES   Garcia        Tetap  Jan                 19                 3
## # ... with 2 more variables: sick.frequency <dbl>, leave.frequency <dbl>
```

6.3 select()

Digunakan untuk memilih variabel dari *dataset*. Jika `filter()` dilakukan untuk melakukan pemilihan atas variabel tertentu, sedangkan `select()` digunakan untuk memilih variabel yang akan digunakan.

Contoh:

Kita akan memilih variabel `dept` dan `sick.frequency` dari data tersebut.

```
data %>% select(dept,sick.frequency)
```

```
## # A tibble: 3,889 x 2
##    dept  sick.frequency
##    <chr>          <dbl>
##  1 JES                0
##  2 JES                0
##  3 JES                1
##  4 JES                0
##  5 JES                0
##  6 JES                0
##  7 JES                5
##  8 JES                0
##  9 JES                0
## 10 JES                1
## # ... with 3,879 more rows
```

Misalkan kita hendak memilih semua variabel yang mengandung kata *frequency*, kita bisa lakukan hal berikut:

```
data %>% select(contains('frequency'))
```

```
## # A tibble: 3,889 x 4
##    tardines.frequency permit.frequency sick.frequency leave.frequency
##                 <dbl>            <dbl>          <dbl>           <dbl>
##  1                  2                2              0               3
##  2                  0                0              0               3
##  3                  0                1              1               1
##  4                  3                1              0               2
##  5                  0                1              0               1
##  6                  0                2              0               1
##  7                  9                1              5               0
##  8                  8                2              0               3
##  9                  3                2              0               0
## 10                  0                2              1               3
## # ... with 3,879 more rows
```

6.4 mutate()

Digunakan untuk membuat dan menghitung variabel baru atau *existing*.

Misalkan kita hendak membuat variabel baru bernama `telat.y.n` yang gunanya untuk mengecek apakah karyawan di bulan tersebut pernah telat atau tidak:

```
data %>%
  mutate(telat.y.n = ifelse(tardines.frequency>0,'Yes','No')) %>%
  select(dept,nama.karyawan,bulan,telat.y.n)
```

```
## # A tibble: 3,889 x 4
##    dept  nama.karyawan bulan telat.y.n
##    <chr> <chr>         <chr> <chr>
##  1 JES   Jimenez       Jan   Yes
##  2 JES   Mccarthy      Mar   No
##  3 JES   Topaha        Jan   No
##  4 JES   el-Ghanem     Mar   Yes
##  5 JES   Topaha        Mei   No
##  6 JES   Lofton        Mei   No
##  7 JES   Porambo       Apr   Yes
##  8 JES   Porambo       Feb   Yes
##  9 JES   Porambo       Mei   Yes
## 10 JES   Jimenez       Mei   No
## # ... with 3,879 more rows
```

Misalkan kita hendak me- *replace* variabel `tardines.frequency` dan menggantinya menjadi 3 kelompok kelas (low, med, high):

```
data %>%
  filter(tardines.frequency>0) %>% # melakukan filter hanya utk karyawan yag telat
  filter(status == "Tetap") %>% # hanya yang statusnya tetap
  filter(bulan == 'Jan') %>% # hanya pada bulan Jan
  mutate(tardines.frequency = cut(tardines.frequency,
                                  3,
                                  labels=c('low','med','high'))) # membagi tardines menjadi 3 kelas
```

```
## # A tibble: 185 x 8
##    dept  nama.karyawan status bulan tardines.freque~ permit.frequency
##    <chr> <chr>         <chr>  <chr> <fct>                        <dbl>
##  1 JES   Jimenez       Tetap  Jan   low                              2
##  2 JES   el-Ghanem     Tetap  Jan   low                              0
##  3 JES   Porambo       Tetap  Jan   low                              1
##  4 JES   Nicklas       Tetap  Jan   low                              0
##  5 JES   Marsh         Tetap  Jan   low                              3
##  6 JES   Noon          Tetap  Jan   low                              3
##  7 JES   Herrera       Tetap  Jan   high                             1
##  8 JES   Littrell      Tetap  Jan   low                              2
##  9 JES   Garcia        Tetap  Jan   high                             3
## 10 JES   Kim           Tetap  Jan   low                              0
## # ... with 175 more rows, and 2 more variables: sick.frequency <dbl>,
## #   leave.frequency <dbl>
```

Fungsi `cut()` membagi data numerik menjadi kelas-kelas tertentu Untuk melakukan *vectorize* dari *conditional* `ifelse()`, kita bisa menggunakan fungsi `case_when()`.

6.5 group_by() dan summarise()

Digunakan untuk melakukan pengelompokkan serta membuat dan menghitung variabel baru atau *existing* berdasarkan pengelompokkan tersebut.

Contoh:

Menghitung berapa banyak karyawan setiap bulannya:

```
data %>%
  group_by(bulan) %>%
  summarise(number_of_employee = length(unique(nama.karyawan)))
```

```
## # A tibble: 5 x 2
##   bulan number_of_employee
##   <chr>              <int>
## 1 Apr                  667
## 2 Feb                  657
## 3 Jan                  659
## 4 Mar                  660
## 5 Mei                  658
```

Menghitung berapa banyak karyawan yang sakit setiap bulannya:

```
data %>%
  filter(sick.frequency > 0) %>%
  group_by(bulan) %>%
  summarise(number_of_sick_employee = length(unique(nama.karyawan)))
```

```
## # A tibble: 5 x 2
##   bulan number_of_sick_employee
##   <chr>                   <int>
## 1 Apr                       211
## 2 Feb                       177
## 3 Jan                       190
## 4 Mar                       211
## 5 Mei                       213
```

Menghitung berapa rata-rata frekuensi cuti dari karyawan setiap bulannya:

```
data %>%
  filter(leave.frequency > 0) %>%
  group_by(bulan) %>%
  summarise(leave_avg = mean(leave.frequency))
```

```
## # A tibble: 5 x 2
##   bulan leave_avg
##   <chr>     <dbl>
## 1 Apr        1.79
## 2 Feb        1.92
## 3 Jan        2.14
## 4 Mar        1.92
## 5 Mei        1.63
```

6.6 separate()

Digunakan untuk memecah satu variabel ke dua atau lebih variabel.

Contoh: misalkan kita memiliki data sebagai berikut:

Table 1: Absensi Karyawan

id	nama
1	el-Hashemi, Naseefa
2	el-Huda, Amaanullah
3	Salazar, Traivon
4	Jones, Fredlyn
5	al-Akbar, Nameera
6	el-Sharif, Waddaah
7	el-Hussein, Mus'ab
8	al-Noorani, Abdul Kareem
9	Rojo, Anyssa
10	Asare, Millicent

Kita hendak memisahkan antara `first.name` dan `last.name` berdasarkan koma (`,`).

```
data_new %>%
  separate(nama,
           into = c('first.name','last.name'),
           sep = '\\,')
```

```
##    id first.name     last.name
## 1   1 el-Hashemi       Naseefa
## 2   2    el-Huda    Amaanullah
## 3   3    Salazar       Traivon
## 4   4      Jones       Fredlyn
## 5   5   al-Akbar       Nameera
## 6   6  el-Sharif       Waddaah
## 7   7 el-Hussein        Mus'ab
## 8   8 al-Noorani  Abdul Kareem
## 9   9       Rojo        Anyssa
## 10 10      Asare     Millicent
```

Jika diperhatikan ada penggunaan \\ pada saat *separate* (`sep =`). Ini artinya kita hanya ingin menggunakan simbol setelah penggunaan \\ yakni (`,`) .

7 Beberapa Fungsi Statistik

Beberapa fungsi statistik yang kita ketahui di **Ms. Excel** juga memiliki nama yang sama di **R**
Biasanya, yang sering kita gunakan itu adalah:

7.1 `sum()`

Menghitung *sum* dari data berupa *vector*.

7.2 `mean()`

Menghitung *mean* dari data berupa *vector*.

7.3 `median()`

Menghitung *median* dari data berupa *vector*.

7.4 `sd()`

Menghitung *standar deviasi* dari data berupa *vector*.

8 Menggabungkan Data

Seringkali kita berurusan dengan beberapa *datasets* dan mengharuskan kita untuk menggabungkan beberapa *datasets* tersebut.

Contoh paling sederhana adalah melakukan *vlookup* seperti yang biasa kita lakukan pada Ms. Excel.

Di **R**, kita tidak hanya bisa melakukan *vlookup* saja tapi bisa juga teknik penggabungan data yang lain.

8.1 `merge()`

`merge()` biasa digunakan untuk menggabungkan dua data dengan prinsip yang sama dengan *vlookup*, yakni harus ada *key id* variabel yang sama antara dua data tersebut.

Misalkan saya punya *dataset* pertama (`data_1`) sebagai berikut:

Table 2: Dataset Pertama

bulan	number_of_employee
Apr	667
Feb	657
Jan	659
Mar	660
Mei	658

Saya ingin menggabungkan *dataset* di atas dengan *dataset* kedua (`data_2`) berikut ini:

Table 3: Dataset Kedua

bulan	number_of_chairs
Jan	648
Feb	651
Mar	682
Apr	687
Mei	677

Jika kita hendak melakukan `merge()`, kita bisa lakukan dengan dua cara:

8.1.1 Cara Klasik

```
merge(data_1,data_2)
```

```
##   bulan number_of_employee number_of_chairs
## 1   Apr                667              687
## 2   Feb                657              651
## 3   Jan                659              648
## 4   Mar                660              682
## 5   Mei                658              677
```

8.1.2 Menggunakan Tidyverse

```
data_1 %>% merge(data_2)
```

```
##   bulan number_of_employee number_of_chairs
## 1   Apr                667              687
## 2   Feb                657              651
## 3   Jan                659              648
## 4   Mar                660              682
## 5   Mei                658              677
```

Perintah `merge()` ini juga memiliki banyak fitur lainnya. Coba kalian cek dengan perintah `?merge` untuk melihat apa saja yang bisa dilakukan.

8.2 rbind()

`rbind()` dilakukan jika kita hendak menggabungkan dua *datasets* yang memiliki *variable names* yang sama. Berbeda dengan prinsip *vlookup*, penggabungan ini adalah hanya menaruh data kedua dibawah urutan data pertama.

Contohnya, saya punya dataset pertama (`data_3`) sebagai berikut:

Table 4: Dataset Pertama

bulan	number_of_sick_employee
Apr	211
Feb	177
Jan	190
Mar	211
Mei	213

Lalu kita hendak menggabungkannya dengan *dataset* kedua (`data_4`) berikut ini:

Table 5: Dataset Kedua

bulan	number_of_sick_employee
Jun	190
Jul	170
Agu	209
Sep	201
Okt	155

Maka caranya adalah:

8.2.1 Cara Klasik

```
rbind(data_3,data_4)
```

```
## # A tibble: 10 x 2
##    bulan number_of_sick_employee
##    <chr>                   <int>
##  1 Apr                       211
##  2 Feb                       177
##  3 Jan                       190
##  4 Mar                       211
##  5 Mei                       213
##  6 Jun                       190
##  7 Jul                       170
##  8 Agu                       209
##  9 Sep                       201
## 10 Okt                       155
```

8.2.2 Menggunakan `Tidyverse`

```
data_3 %>% rbind(data_4)
```

```
## # A tibble: 10 x 2
##    bulan number_of_sick_employee
##    <chr>                   <int>
##  1 Apr                       211
##  2 Feb                       177
##  3 Jan                       190
##  4 Mar                       211
##  5 Mei                       213
##  6 Jun                       190
##  7 Jul                       170
##  8 Agu                       209
##  9 Sep                       201
## 10 Okt                       155
```

Perintah `rbind()` ini juga bisa dilakukan untuk menggabungkan dua *datasets* yang *variable names*-nya ada yang berbeda. Jadi tidak harus sama, tapi minimal ada satu yang sama.

Misalkan dua *datasets* ini:

```
data_new_1
```

```
##   bulan number_of_employee number_of_chairs
## 1   Apr                667              687
## 2   Feb                657              651
## 3   Jan                659              648
## 4   Mar                660              682
## 5   Mei                658              677
```

```
data_new_2
```

```
## # A tibble: 10 x 2
##    bulan number_of_sick_employee
##    <chr>                  <int>
##  1 Apr                      211
##  2 Feb                      177
##  3 Jan                      190
##  4 Mar                      211
##  5 Mei                      213
##  6 Jun                      190
##  7 Jul                      170
##  8 Agu                      209
##  9 Sep                      201
## 10 Okt                      155
```

```
data_new_1[setdiff(names(data_new_2), names(data_new_1))] = NA
data_new_2[setdiff(names(data_new_1), names(data_new_2))] = NA
rbind(data_new_1,data_new_2)
```

```
##    bulan number_of_employee number_of_chairs number_of_sick_employee
## 1    Apr                667              687                     NA
## 2    Feb                657              651                     NA
## 3    Jan                659              648                     NA
## 4    Mar                660              682                     NA
## 5    Mei                658              677                     NA
## 6    Apr                 NA               NA                    211
## 7    Feb                 NA               NA                    177
## 8    Jan                 NA               NA                    190
## 9    Mar                 NA               NA                    211
## 10   Mei                 NA               NA                    213
## 11   Jun                 NA               NA                    190
## 12   Jul                 NA               NA                    170
## 13   Agu                 NA               NA                    209
## 14   Sep                 NA               NA                    201
## 15   Okt                 NA               NA                    155
```

Ingat *yah*, hanya menaruh *dataset* kedua secara berurut ada di bawah *dataset* pertama.

---

9 *Libraries* yang Berguna

Pada *section* `1.7` saya sempat menyebutkan beberapa *libraries* yang berguna. Faedah dari `library(dplyr)` sudah termasuk dalam pembahasan `library(tidyverse)`. Oleh karena itu, saya akan coba bahas *libraries* lainnya satu- persatu.

9.1 `library(janitor)`

Pada *section* `2.2` saya telah menyebutkan *library* yang satu ini. Salah satu faedahnya yang sering saya pakai adalah untuk membersihkan nama variabel (`colnames()`) dari suatu `data.frame`. Tapi tidak menutup kemungkinan digunakan juga untuk membersihkan *text* pada saat kita hendak melakukan *text analysis*.

9.1.1 *Function* `make_clean_names()`

Function ini berguna untuk membuat membersihkan data berbentuk *character* dengan cara:

1. Membuat *character* menjadi *lowercase*.
2. Mengubah spasi menjadi *underscore* `_`.
3. Menghilangkan tanda baca dan *non alpha numeric character*.

Contohnya: misalkan saya memiliki *vector* berisi *string* sebagai berikut:

```
kata = c('Pulang pergi','Selamat Pagi','kamu siapa?','Nama (lengkap...)','Bersiap! 1,2,3!')
kata
```

```
## [1] "Pulang pergi"      "Selamat Pagi"      "kamu siapa?"
## [4] "Nama (lengkap...)" "Bersiap! 1,2,3!"
```

Perhatikan *output* dari *function* ini:

```
library(janitor)
```

```
##
## Attaching package: 'janitor'
```

```
## The following objects are masked from 'package:stats':
##
##     chisq.test, fisher.test
```

```
make_clean_names(kata)
```

```
## [1] "pulang_pergi"  "selamat_pagi"  "kamu_siapa"    "nama_lengkap"
## [5] "bersiap_1_2_3"
```

9.1.2 *Function* clean_names()

Function ini digunakan untuk membersihkan colnames() dari suatu data.frame.

Misalkan: saya memiliki data seperti ini:

Table 6: Data Harian COVID-19

Tanggal Lapor	Kasus baru	Kasus Impor	Kasus Lokal	Total kasus	Kasus aktif	% kasus aktif
2020-03-02	2	0	2	2	2	1.0000000
2020-03-03	0	0	0	2	2	1.0000000
2020-03-04	0	0	0	2	2	1.0000000
2020-03-05	0	0	0	2	2	1.0000000
2020-03-06	2	0	2	4	4	1.0000000
2020-03-07	0	0	0	4	4	1.0000000
2020-03-08	2	1	1	6	6	1.0000000
2020-03-09	13	7	6	19	19	1.0000000
2020-03-10	8	5	3	27	27	1.0000000
2020-03-12	0	0	0	34	27	0.7941176

Seperti yang telah disebutkan sebelumnya, penamaan variabel sebisa mungkin dibuat simpel agar penulisan *script* menjadi lebih cepat dan mudah. Berikut adalah nama variabel (colnames()) dari data.frame tersebut:

```
colnames(data)
```

```
## [1] "Tanggal Lapor" "Kasus baru"    "Kasus Impor"   "Kasus Lokal"
## [5] "Total kasus"   "Kasus aktif"   "% kasus aktif"
```

Untuk mengubahnya, kita bisa menggunakan salah satu dari dua cara berikut ini:

- Cara tidyverse

```
data_new_1 = data %>% clean_names()
head(data_new_1,10)
```

```
## # A tibble: 10 x 7
##    tanggal_lapor       kasus_baru kasus_impor kasus_lokal total_kasus
##    <dttm>                   <dbl>       <dbl>       <dbl>       <dbl>
##  1 2020-03-02 00:00:00          2           0           2           2
##  2 2020-03-03 00:00:00          0           0           0           2
##  3 2020-03-04 00:00:00          0           0           0           2
##  4 2020-03-05 00:00:00          0           0           0           2
##  5 2020-03-06 00:00:00          2           0           2           4
##  6 2020-03-07 00:00:00          0           0           0           4
##  7 2020-03-08 00:00:00          2           1           1           6
##  8 2020-03-09 00:00:00         13           7           6          19
##  9 2020-03-10 00:00:00          8           5           3          27
## 10 2020-03-12 00:00:00          0           0           0          34
## # ... with 2 more variables: kasus_aktif <dbl>, percent_kasus_aktif <dbl>
```

- Cara `klasik`

```
data_new_2 = clean_names(data)
head(data_new_2,10)
```

```
## # A tibble: 10 x 7
##    tanggal_lapor       kasus_baru kasus_impor kasus_lokal total_kasus
##    <dttm>                   <dbl>       <dbl>       <dbl>       <dbl>
##  1 2020-03-02 00:00:00          2           0           2           2
##  2 2020-03-03 00:00:00          0           0           0           2
##  3 2020-03-04 00:00:00          0           0           0           2
##  4 2020-03-05 00:00:00          0           0           0           2
##  5 2020-03-06 00:00:00          2           0           2           4
##  6 2020-03-07 00:00:00          0           0           0           4
##  7 2020-03-08 00:00:00          2           1           1           6
##  8 2020-03-09 00:00:00         13           7           6          19
##  9 2020-03-10 00:00:00          8           5           3          27
## 10 2020-03-12 00:00:00          0           0           0          34
## # ... with 2 more variables: kasus_aktif <dbl>, percent_kasus_aktif <dbl>
```

9.2 library(lubridate)

Beberapa kali saya dihadapkan pada data tanggal dan waktu. Untuk itu, saya biasa menggunakan `library(lubridate)` untuk membantu saya untuk melakukannya. Mari kita lihat kembali data COVID-19 yang sudah kita bersihkan sebelumnya:

Table 7: 5 Data Teratas dari Data COVID-19 Cleaned

tanggal_lapor	kasus_baru	kasus_impor	kasus_lokal	total_kasus	kasus_aktif	percent_kasus_aktif
2020-03-02	2	0	2	2	2	1
2020-03-03	0	0	0	2	2	1
2020-03-04	0	0	0	2	2	1
2020-03-05	0	0	0	2	2	1
2020-03-06	2	0	2	4	4	1

Kita coba cek tipe data dari masing-masing variabel yang ada pada data tersebut:

```
str(data_new_2)
```

```
## tibble [139 x 7] (S3: tbl_df/tbl/data.frame)
##  $ tanggal_lapor      : POSIXct[1:139], format: "2020-03-02" "2020-03-03" ...
##  $ kasus_baru         : num [1:139] 2 0 0 0 2 0 2 13 8 0 ...
##  $ kasus_impor        : num [1:139] 0 0 0 0 0 0 1 7 5 0 ...
##  $ kasus_lokal        : num [1:139] 2 0 0 0 2 0 1 6 3 0 ...
##  $ total_kasus        : num [1:139] 2 2 2 2 4 4 6 19 27 34 ...
##  $ kasus_aktif        : num [1:139] 2 2 2 2 4 4 6 19 27 27 ...
##  $ percent_kasus_aktif: num [1:139] 1 1 1 1 1 ...
```

Ternyata variabel `tanggal_lapor` tidak bertipe `date`. Oleh karena itu, kita akan *convert* ke tipe `date` dengan *function* yang ada di `library(lubridate)` yakni `date()`.

```
library(lubridate)

data_new_2 =
  data_new_2 %>%
  mutate(tanggal_lapor = date(tanggal_lapor))

str(data_new_2)
```

```
## tibble [139 x 7] (S3: tbl_df/tbl/data.frame)
##  $ tanggal_lapor      : Date[1:139], format: "2020-03-02" "2020-03-03" ...
##  $ kasus_baru         : num [1:139] 2 0 0 0 2 0 2 13 8 0 ...
##  $ kasus_impor        : num [1:139] 0 0 0 0 0 0 1 7 5 0 ...
##  $ kasus_lokal        : num [1:139] 2 0 0 0 2 0 1 6 3 0 ...
##  $ total_kasus        : num [1:139] 2 2 2 2 4 4 6 19 27 34 ...
##  $ kasus_aktif        : num [1:139] 2 2 2 2 4 4 6 19 27 27 ...
##  $ percent_kasus_aktif: num [1:139] 1 1 1 1 1 ...
```

Sekarang `tanggal_lapor` sudah bertipe `date`, oleh karena itu kita bisa mengekstrak beberapa informasi lain terkait waktu sebagai berikut:

```
data_tanggal =
  data_new_2 %>%
  mutate(
    bulan = month(tanggal_lapor,label = T),
    tahun = year(tanggal_lapor),
    tanggal = day(tanggal_lapor),
    hari = wday(tanggal_lapor,label = T),
    total_hari_sebulan = days_in_month(tanggal_lapor),
    minggu_ke = epiweek(tanggal_lapor)
  ) %>%
  select(tanggal_lapor,bulan,tahun,tanggal,hari,total_hari_sebulan,minggu_ke)
```

Table 8: Hasil Ekstrak Data Tanggal

tanggal_lapor	bulan	tahun	tanggal	hari	total_hari_sebulan	minggu_ke
2020-03-02	Mar	2020	2	Sen	31	10
2020-03-03	Mar	2020	3	Sel	31	10
2020-03-04	Mar	2020	4	Rab	31	10
2020-03-05	Mar	2020	5	Kam	31	10
2020-03-06	Mar	2020	6	Jum	31	10

Selain *functions* yang saya gunakan di atas, silakan di-*explore functions* apalagi yang bisa digunakan dari `library(lubridate)`.

9.3 library(ggplot2)

Seringkali kita harus membuat grafik atau visualisasi dari data yang kita olah. Salah satu *library* yang paling *powerful* untuk melakukan itu di **R** adalah `library(ggplot2)`.

Hampir semua elemen dalam grafik bersifat *customize* dan bisa diubah melalui *script*. Kalian bisa mengecek semua yang bisa dilakukan di situs berikut ini:

1. *Ggplot2 essential*.
2. *Top 50 ggplot visualization*.
3. *R graph gallery*.

Salah satu contohnya dari data COVID-19 di atas adalah sebagai berikut:

```
library(ggplot2)

data_new_2 %>%
  ggplot(aes(x = tanggal_lapor,
             y = kasus_baru)) +
  geom_smooth(method = 'loess',
              color = 'cyan',
              fill = 'magenta',
              alpha = .2) +
  geom_line(color = 'darkred') +
  labs(x = 'Tanggal',
       y = 'Kasus Baru',
       title = 'Tren Penambahan Kasus Baru di Indonesia',
       subtitle = 'Sumber data: Rekap Situs Kawal Covid 19',
       caption = 'Visualized using R\nikanx101.github.io') +
  theme_minimal()
```

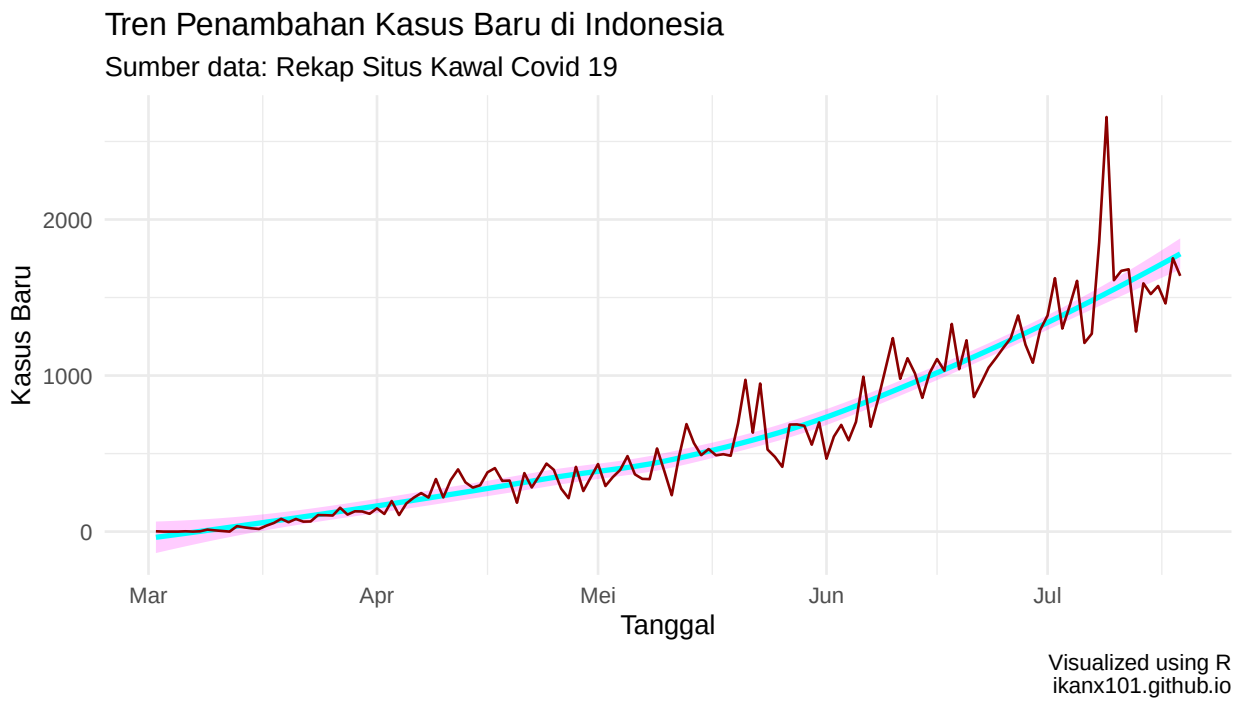

9.4 library(reshape2)

Seringkali kita berhadapan dengan bentuk data yang menyamping. Bentuk data tersebut tidak tabular dan akan menyulitkan bagi kita untuk melakukan analisa.

Kali ini saya akan menggunakan data contoh COVID-19 yang saya simpan di *link* berikut ini. Silakan diunduh untuk bisa mencobanya juga bersama-sama.

Mari kita *import* datanya ke dalam **R**. Berikut tampilannya:

Table 9: Contoh Data Tidak Tabular (hanya ditampilkan 10 kolom pertama saja)

Total Kasus	18-Mar	19-Mar	20-Mar	21-Mar	22-Mar	23-Mar	24-Mar	25-Mar	26-Mar	27-Mar
Jakarta	158	210	215	267	307	353	424	463	515	598
Jabar	24	26	41	55	59	59	60	73	78	98
Jateng	8	12	12	14	15	15	19	38	40	43
Jatim	8	9	15	26	41	41	51	51	59	66

Sebagai informasi, data ini berisi `125` kolom dengan kolom pertama adalah `Total Kasus` sedangkan `124` kolom lainnya adalah tanggal.

```
library(reshape2)
colnames(data)[1] = 'provinsi'

data_baru =
  data %>%
  melt(id.vars = 'provinsi')
```

Table 10: 15 Data Teratas dari Hasil Konversi Ke Tabular

provinsi	variable	value
Jakarta	18-Mar	158
Jabar	18-Mar	24
Jateng	18-Mar	8
Jatim	18-Mar	8
Jakarta	19-Mar	210
Jabar	19-Mar	26
Jateng	19-Mar	12
Jatim	19-Mar	9
Jakarta	20-Mar	215
Jabar	20-Mar	41
Jateng	20-Mar	12
Jatim	20-Mar	15
Jakarta	21-Mar	267
Jabar	21-Mar	55
Jateng	21-Mar	14

Didapatkan data_baru berisi 496 baris hasil konversi.

```
str(data_baru)
```

```
## 'data.frame':    496 obs. of  3 variables:
##  $ provinsi: chr  "Jakarta" "Jabar" "Jateng" "Jatim" ...
##  $ variable: Factor w/ 124 levels "18-Mar","19-Mar",..: 1 1 1 1 2 2 2 2 3 3 ...
##  $ value   : num  158 24 8 8 210 26 12 9 215 41 ...
```

Dengan bentuk data seperti ini, kita bisa melakukan analisa *pivot* berdasarkan provinsi.

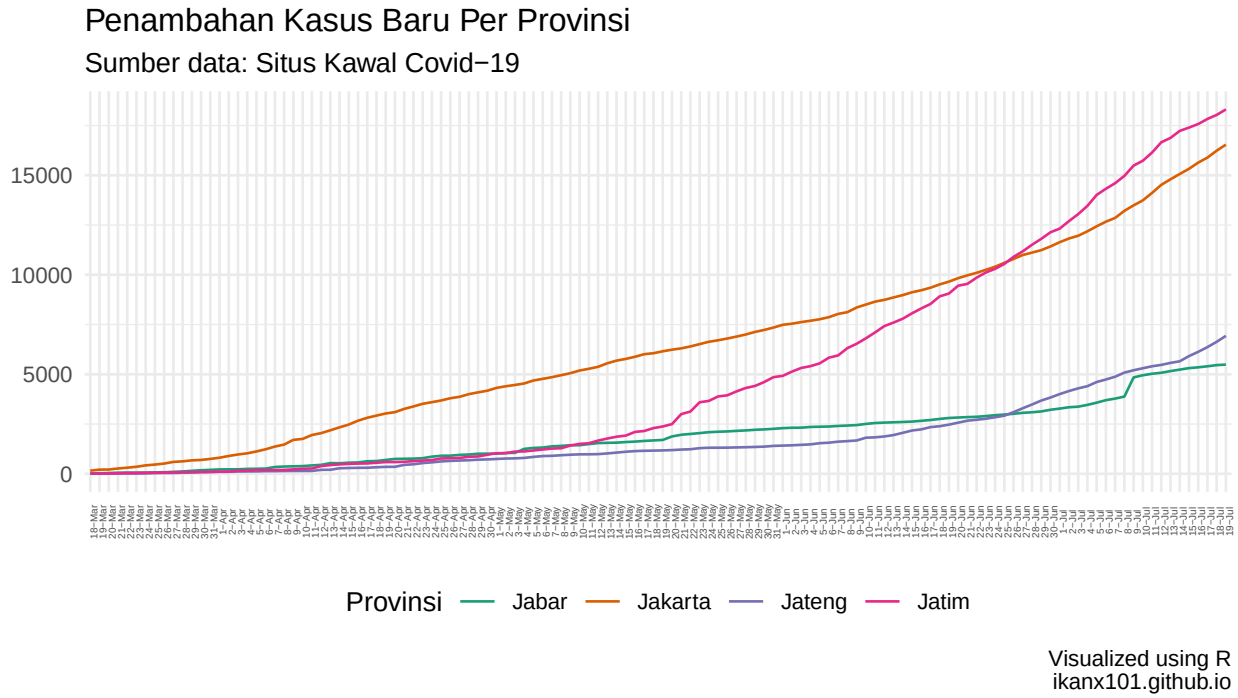

9.5 library(tidytext)

9.6 library(rvest)

10 APLIKASI R DI DUNIA REAL

Berikut akan saya sampaikan beberapa contoh kasus yang diselesaikan menggunakan R.

10.1 Membuat Alat Deteksi Cepat COVID-19

Beberapa orang peneliti sedang

Referensi

1. Metode Numerik Menggunakan R Untuk Teknik Lingkungan, Mohammad Rosidi: R bookdown.
2. Cara Install R di Android.
3. Install R base for Windows.
4. Install R Studio.
5. R Studio Cloud.
6. Bookdown, e-book from R Markdown.
7. Menggunakan R Studio Cloud di Android browser.
8. NOMNOML: How to make diagram in R.
9. Beberapa *puzzles* yang bisa diselesaikan dengan simulasi **Monte Carlo**.